传智杯 AI-Web 网页开发挑战赛 · 系统架构与工程技术说明书

SpeakPal 技术文档

可验证的场景化 AI 英语口语诊断陪练系统 ——
融合客观规则评分、人机一致性统计检验与 SM-2 间隔重复学习闭环

产品名称	SpeakPal · 可验证的 AI 英语口语诊断陪练	**代码版本**	后端 FastAPI 0.2.0 / 前端 speakpal-frontend@0.2.0
文档版本	v2.2（对齐当前仓库全量实现）	**更新日期**	2026-11-14
核心技术栈	Vue 3 + Vite + Tailwind CSS / FastAPI + SQLAlchemy 2 + SQLite	**验证工具链**	Python 纯标准库 evaluation/ + tools/check_content.py
适用读者	竞赛评委、前后端开发者、测试与运维人员	**覆盖范围**	架构设计、数据模型、API 规格、融合评分、SM-2 闭环、信效度验证与部署

文档设计准则与真实性声明
本文档严格依据当前工作区代码实况编写，凡涉及行为、表结构、路由、公式与默认值的描述均与源码逐行对齐。设计基线见 docs/design.md，量表推导见 docs/rubric-band.md，离线统计口径见 docs/validation.md；三者与本文冲突时以代码为准。

1. 项目概述与核心定位

1.1 产品定位：SpeakPal 是面向高校学生与英语学习者的**场景化 AI 英语口语诊断陪练系统。**用户注册登录后，可从 6 个高频真实交际场景（求职面试、咖啡店点单、雅思 Part 1、酒店入住、机场值机、餐厅点餐）中任选其一，通过语音录入或打字输入与 AI 角色进行多轮沉浸式对话（支持 SSE 流式回复与语音合成朗读）。练习结束后，系统输出 0–100 综合分、随作答方式动态裁剪的维度分、IELTS Band（0.5 步长）与 CEFR 等级（A2–C2），并提供逐句「更地道说法」改写与客观流利度指标，同时将错句自动沉淀为 SM-2 间隔重复学习卡片。

1.2 差异化创新点：同类口语应用多停留在「能调用大模型聊天、黑盒打一个总分」。SpeakPal 在工程上重点打通了三大闭环：① **可解释融合评分**：把语音包络停顿特征、文本词汇多样性（MTLD/TTR）、句法复杂度与场景交际清单转化为客观规则分，对大模型评分实施「只压不抬」约束；② **可复现统计验证**：内置零第三方依赖的 evaluation/ 子系统，用 ICC(2,1)/ICC(2,k)、Kappa、Bland-Altman 等指标与教师盲评金标准对齐；③ **诊学一体闭环**：把报告错句、85% 阈值跟读重说、最小对立对发音辨析与内置 720 条离线教研卡片（600 词库 + 60 语法 + 60 口语）统一纳入 SM-2 复习调度。

模块域	核心功能	关键技术实现	代码入口
认证与安全	注册/登录、改密踢旧设备、防暴破、SSRF 防护	PBKDF2-SHA256（12 万次迭代）+ JWT（含 token_version 代次）+ 私网 IP 拦截	app/security.py, app/services/outbound.py
多轮场景对练	6 大场景、3 档难度、句型脚手架、SSE 流式回复	保留最近 8 条消息（约 4 轮问答）上下文；SSE 完整生成后落库，失败自动回退普通接口	app/routers/sessions.py, src/api/stream.js
双模态与音频	Web Speech 语音转写、Web Audio 停顿检测、本地回放	50ms 窗口 RMS > 0.02 判有声，≥0.15s 静默记停顿；MediaRecorder + IndexedDB 本地存音频	src/utils/speech.js, audio.js, recordings.js
融合诊断报告	动态 3/4/5 维评分、IELTS/CEFR 换算、跨模式可比档	模型 Band 与规则子分按权重融合 + 超 20 分截断；明细落库 scoring_json	app/services/scoring.py, rules.py, evaluation/bands.py

模块域	核心功能	关键技术实现	代码入口
专项发音训练	错句跟读重说（Drills）、最小对立对辨析（Minimal Pairs）	词级相似度 ≥0.85 通关；内置 2 组 × 10 对易混音素对立训练	app/routers/exercises.py, services/pronunciation.py
SM-2 学习闭环	今日待复习队列、高考/四六级词库、语法卡、地道口语卡	简化 SM-2 间隔重复（again/hard/good 三档）+ 720 条离线 JSON 题库 + 随堂笔记 CRUD	app/routers/study.py, services/srs.py, wordbank.py, library.py
数据看板与后台	Streak 连续天数、12 周热力图、维度均分、Admin 控制台	按 tz_offset 本地时区切日聚合；单页管理台支持用户管理与存储迁移	app/services/dashboard.py, static/admin.html
离线统计验证	人评内部信度、人机一致性效度、教研内容静态质检	纯标准库 ANOVA 求 ICC、Kappa、Bland-Altman；词形屈折匹配检查	evaluation/agreement.py, tools/check_content.py

1.3 诚实边界与非目标声明（答辩高频追问点）
① 不做音素级声学建模：发音维度由大模型结合语音识别转写特征推断，正常报告注脚为「分数由模型分与可测规则分融合得出，仅供参考」；② 服务端不保存用户原始录音，仅入库时长与停顿统计元信息（audio_json），录音回放仅限本浏览器 IndexedDB；③ evaluation/demo_data.csv 为固定随机种子（seed=42）生成的 20 条合成样本，用于验证统计流水线可复现，不冒充真人实测结论；④ 无多租户 / 班级 / 教师端，管理台仅做只读统计与账号运维。

2. 系统总体架构与技术选型

2.1 逻辑架构与进程拓扑

系统采用前后端分离 + 离线评估包共享特征层的三层架构。开发与演示环境下，前端运行于 Vite Dev Server（127.0.0.1:5173），通过 /api 反向代理与 FastAPI 后端（127.0.0.1:8000）通信；后端经 SQLAlchemy 2.x 访问 SQLite（backend/speakpal.db，10 张表），并通过 httpx 调用 OpenAI 兼容大模型接口与可选 TTS 接口。evaluation/ 包既可作为离线 CLI 独立运行，又被后端运行时直接导入，以保证线上报告与离线验证的特征提取、档位换算口径完全一致。

【浏览器端 Chrome / Edge (127.0.0.1:5173)】
├─ Vue 3 SPA：12 个页面视图 (Login / Home / Practice / Report / History / Review / StudyHome / StudyScope / StudyLearn / Notes / Pronunciation / Settings) + catch-all 兜底
├─ 语音与音频层：Web Speech API (转写 & 内置朗读) · Web Audio API (50ms RMS 包络采样) · MediaRecorder + IndexedDB (本地录音回放)
└─ 通信与状态层：Pinia (auth / session / settings) · Axios (Bearer JWT + X-LLM-Key / X-TTS-Key 头注入) · Fetch + ReadableStream (SSE)
│ HTTP REST / JSON 与 Server-Sent Events（开发环境经 Vite /api 代理转发）
▼
【FastAPI 后端服务 (uvicorn 127.0.0.1:8000)】
├─ 路由层 routers/：auth · scenes · sessions · reports · exercises · hints · study · words · account · system · tts · admin（共 61 个 /api 操作，落在 54 条路径上）
├─ 服务层 services/：agent (目标规划 / Critic / 结束判定) · llm (多轮对话 & SSE) · scoring (评分编排) · rules (规则分与融合) · srs (SM-2) · study · dashboard
│ · wordbank · library · pronunciation · outbound (SSRF 防护) · llm_config · storage · user_data
├─ 共享计算层：直接复用仓库根目录 evaluation.features（文本/语音特征）、evaluation.bands（权重 / IELTS Band / CEFR / 可比档）与 evaluation.scales（多量表）
└─ 数据与静态层：SQLAlchemy 2.x → SQLite（10 张表）｜内置离线题库 data/*.json｜运营后台 /admin 与离线 Swagger /docs｜tests/ unittest 回归

2.2 技术选型与工程取舍

架构层	核心组件	版本约束	选型理由与关键工程取舍
前端框架	Vue 3（<script setup>）	^3.5.0	组合式 API 高内聚，单文件组件开发效率高，便于多视图交互状态管理
前端构建与样式	Vite 5 + Tailwind CSS 3	^5.4.0 / ^3.4.10	毫秒级热更新，内置 /api 反代消除跨域；原子类结合 style.css 统一定制视觉规范
状态与路由	Pinia 2 + Vue Router 4	^2.2.0 / ^4.4.0	History 路由配合全局前置守卫实现未登录拦截，并按 X-Auth-Reason 精准回跳
后端框架	FastAPI + Uvicorn	>=0.110	基于 Pydantic 自动生成 OpenAPI 契约，配合本地化静态资源提供离线 /docs 文档
ORM 与数据库	SQLAlchemy 2.x + SQLite	>=2.0 / 内置	单文件零外部服务依赖；main.py 启动期 _ensure_schema() 实现幂等自动补列迁移
密码与鉴权	hashlib.pbkdf2 + PyJWT	标准库 / >=2.8	PBKDF2-SHA256 规避 bcrypt 原生编译兼容问题；JWT 载荷引入 token_version 支持改密踢旧设备
AI 接口通信	httpx（OpenAI 兼容协议）	>=0.27	不绑定单一厂商 SDK，用户可自由切换 DeepSeek / OpenAI / 硅基流动 / 本地 Ollama
离线统计验证	Python 标准库（math / csv）	Python 3.10+	手写双向随机效应 ANOVA 与秩相关，零 numpy/scipy 依赖，确保评委机器开箱即跑

3. 后端架构设计与数据模型

3.1 启动自检、配置优先级与平滑迁移机制

- **弱密钥自动轮换与持久化**：启动时检查 JWT_SECRET 与 ADMIN_KEY，若为空或为公开弱默认值（dev-secret-change-me / admin123 / change-me-to-a-random-long-string），自动用 secrets.token_urlsafe 生成高强度随机密钥并写回 backend/.env；ADMIN_KEY 新值会打印到后端控制台。真实进程环境变量中提供的值不改写，仅告警。
- **四级数据库路径解析**：_resolve_database_url() 按「真实进程环境变量 DATABASE_URL > backend/data_location.json > backend/.env > 默认 sqlite:///./speakpal.db」顺序解析。当进程环境变量锁定时，管理台「改数据位置」接口返回 409 env_override。注意：进程环境快照必须在 load_dotenv() 之前采集，否则 .env 会永远压过 data_location.json。
- **幂等 Schema 自动演进**：SQLite 不支持复杂在线迁移，_ensure_schema() 在每次启动时用 inspect(engine) 探测 reports / turns / users / notes / study_items 表结构，自动补齐新增列（features_json、bands_json、band、cefr、source、mock_reason、answer_mode、comparable_band、scoring_json、token_version、practice_difficulty、word_scope 等）；notes 表还内置了「旧列 content / learning_item_id 重建」的一次性清洗逻辑。仅支持加列，删列与改类型需手工处理。

3.2 数据库表结构设计（10 张核心表）

backend/app/models.py 定义 10 张 SQLAlchemy ORM 实体。所有时间戳以 UTC 无时区写入，接口出参统一由 timeutil.utc_iso 格式化为带 Z 的 ISO-8601 串，前端按本地时区展示。

表名（ORM 类）	主键与索引	核心业务字段	设计约束与业务用途
users (User)	PK: id UK: username（索引）	password_hash, nickname, token_version, practice_difficulty, word_scope, created_at	账号凭据与学习偏好（默认难度 medium、词库范围 cet4）；改密时 token_version 自增 1，使旧设备 JWT 立即 401
sessions (PracticeSession)	PK: id FK: user_id → users.id	scene_id, difficulty, status（active|finished）, created_at	单次场景练习主表；turns 与 report 均配置 cascade='all, delete-orphan' 级联删除
turns (Turn)	PK: id（同时用于轮次保序） FK: session_id → sessions.id	role（ai|user）, content, input_mode（voice|typed）, audio_json, created_at	按自增 id 保序记录对话；user 轮记录输入方式与音频特征 JSON（duration_sec / speech_time_sec / pauses）
reports (Report)	PK: id UNIQUE FK: session_id → sessions.id	total_score, band, cefr, source（llm|mock）, mock_reason, answer_mode, comparable_band, dimensions_json, bands_json, scoring_json, fixes_json, features_json, comment	与会话 1:1 绑定；完整保存综合分、雅思档、跨模式可比档、模型与规则融合明细（scoring_json）与逐句纠错列表
drill_attempts (DrillAttempt)	PK: id FK: report_id → reports.id	item_index, transcript, similarity, created_at	记录对第 item_index 条错句的每次语音跟读转写与词级相似度（≥0.85 判定通过）
study_items (StudyItem)	PK: id FK: user_id, source_session_id	kind（word|phrase|spelling|grammar）, source, term, context, meaning_zh, example, related_json, ease, interval_days, due_at, reps, lapses	SM-2 间隔重复卡片表；统一承载报告自动提炼错卡、高考/四六级新词卡、语法卡与口语表达卡
notes (Note)	PK: id FK: user_id, session_id	title, body, session_id, created_at, updated_at	随堂学习笔记表，支持关联特定练习会话；标题留空时自动截取正文首行

表名（ORM 类）	主键与索引	核心业务字段	设计约束与业务用途
review_events (ReviewEvent)	PK: id FK: user_id, item_id	result（again|hard|good），interval_before, interval_after, created_at	每次复习提交的结果日志；「今天复习了几张」「这条笔记今天复习过没有」按本地日从这张表统计
note_links (NoteLink)	PK: id FK: note_id, item_id	term, start, end, created_at	笔记正文命中的学习卡（纯文本自动识别）；start/end 是正文里的字符位置，同一个词多次出现会留多行
note_link_mutes (NoteLinkMute)	PK: note_id + item_id	created_at	用户手动取消的误关联；同一 (note, item) 只留一行，重新识别时跳过

3.3 核心 JSON 字段契约

字段位置	JSON 结构与关键键名
turns.audio_json	{"duration_sec": 3.2, "speech_time_sec": 2.8, "pauses": [0.22, 0.35]} —— 前端 Web Audio API 采样计算的本轮总时长、有效发声时长与停顿数组（秒）。打字轮为空对象 {}。
reports.scoring_json	每维一条明细：{"model_score": 78.0, "rule_score": 54.0, "final_score": 64.0, "weight_rule": 0.5, "clamped": true, "clamp_reason": "...", "inputs": {...}} —— 完整保存模型原分、规则子分、是否触发压分及计算输入，支撑前端「评分依据」面板原样复现。接口出参字段名是 scoring_detail（库内与响应不同名，查库时注意）。
reports.fixes_json	[{"original": "...", "better": "...", "natural": "...", "error_type": "grammar|spelling|stiffness|wordiness", "reason": "...", "target_term": "...", "meaning_zh": "..."}] —— 逐句纠错数组（1–3 条），驱动错句对比、原声回放与自动生成 study_items 学习卡。
reports.features_json	文本侧：word_count / filler_count / filler_rate / ttr / mtld / sentence_count / mean_sentence_len；音频侧：audio_duration_sec / speech_rate_wpm / articulation_rate_wpm / pause_count / mean_pause_sec / pause_ratio。无录音时音频键缺失，由无声学证据分支直接跳过流利度规则分。
study_items.related_json	{"synonyms": [], "antonyms": [], "similar": []} —— 近义词 / 反义词 / 形近词，API 出参统一解包为三个标准数组。

4. 后端 API 接口全景规格（61 个操作 / 54 条路径）

后端按业务域划分为 12 个路由模块，共 **61 个 /api 操作**（60 条路由注册 + GET /api/health），落在 54 条 /api 路径上；另有 3 个 HTML 页面入口（/、/admin、/docs）。通用约定：① 用户态接口使用 Authorization: Bearer <JWT>，Token 失效时响应头附带 X-Auth-Reason（expired / password_changed / user_gone / token_invalid），并在 CORS 中显式暴露该头；② 管理台接口使用 X-Admin-Key 头（读接口错密钥 401，写接口 403）；③ 大模型与语音密钥由浏览器通过 X-LLM-Key、X-LLM-Base-Url、X-LLM-Model、X-TTS-Key 等请求头按次传入，服务端不落库、不回显。跨域会话归属校验一律返回 404 而非 403，避免泄露会话是否存在。

路由模块	方法与路径	鉴权	功能说明与关键状态码
认证 auth.py（3）	POST /api/auth/register POST /api/auth/login GET /api/auth/me	公开 公开 用户	注册（用户名大小写归一，直接签发 Token，重名 400）；登录（滑动窗口失败计数防暴破，超限 429，账号不存在与密码错误同文案）；取当前用户
场景 scenes.py（2）	GET /api/scenes GET /api/scenes/{scene_id}/frames	用户 用户	6 个内置场景列表（对外隐藏 role / opening 等 prompt 字段）；场景句型脚手架（Frames）中英对照
会话与对话 sessions.py（6）	POST /api/sessions POST /api/sessions/{id}/turn POST /api/sessions/{id}/turn/stream POST /api/sessions/{id}/finish GET /api/sessions/{id} GET /api/sessions	用户	建会话并返回 AI 开场白（无可用 Key → 409 llm_not_configured，Key 被拒 → 502 key_invalid 且不落库）；提交轮次（普通 JSON 或 SSE 流式）；幂等结束并生成报告；会话详情与历史列表
报告 reports.py（1）	GET /api/sessions/{id}/report	用户	读取诊断报告（综合分、Band、CEFR、维度分、scoring_detail 融合明细、流利度特征、逐句纠错）
专项训练 exercises.py（4）	GET /api/sessions/{id}/drills POST /api/sessions/{id}/drills/{idx}/attempt GET /api/pronunciation/minimal-pairs POST /api/pronunciation/check	用户	报告错句跟读队列（含历史最高相似度与 0.85 阈值）；提交跟读转写判分；2 组 × 10 对最小对立对题组；发音辨析判定（correct / partner_heard / reason）
SM-2 学习闭环 study.py（21）	GET /api/study/today GET /api/study/due | /summary GET /api/study/items POST /api/study/items POST /api/study/items/{id}/review DELETE /api/study/items/{id} GET|POST /api/study/vocab(/add) GET|POST /api/study/grammar(/add) GET|POST /api/study/spoken(/add) GET|POST /api/notes， GET|PATCH|DELETE /api/notes/{id} GET /api/notes/{id}/links POST /api/notes/{id}/mutes， DELETE /api/notes/{id}/mutes/{item_id}	用户	今日待复习队列与模块汇总；手动建卡、提交复习（支持 grade 评分或 answer 客观判分驱动 SM-2）；高考/四级/六级词库、语法卡、口语卡查询与批量加卡（自动去重）；随堂笔记 CRUD 与「笔记 ⇄ 已学词」知识链接

路由模块	方法与路径	鉴权	功能说明与关键状态码
提示 hints.py（1）	POST /api/sessions/{id}/hint	用户	按会话目标与最近发言给 3 条可用句式提示；模型不可用时降级为本地句型
单词工具 words.py（4）	POST /api/study/words/assist POST /api/study/words/sentence-check POST /api/study/words/import POST /api/study/words/learn	用户	查词助手（释义 / 例句 / 近反义）；造句检查；批量导入生词；把单词加入学习清单
个人中心与看板 account.py（7）	PATCH /api/me/profile GET|PATCH /api/me/settings GET /api/me/dashboard GET /api/me/recommendation DELETE /api/me/data | /account	用户	改昵称/密码（改密需旧密码，token_version+1 并返回新 Token）；同步难度与词库偏好；学习看板（连续天数 / 12 周热力图 / 维度均分 / 近 7 天变化）；难度建议；清练习记录（scope=records）或注销账号（confirm='注销'）
系统与语音 system.py / tts.py（4）	GET /api/config/llm POST /api/config/llm/test GET /api/system/storage POST /api/tts GET /api/health	用户 ×4 公开	查询默认 LLM 配置；实测浏览器传入 Key 的连通性；查看数据库路径/大小/可写性；TTS 合成（无 Key 409 tts_not_configured，被拒 502 tts_key_invalid，不可达 502 tts_unavailable）；健康检查
运营管理台 admin.py（7）	GET /api/admin/stats | /users | /sessions PATCH|DELETE /api/admin/users/{id} DELETE /api/admin/data PUT /api/admin/storage	管理 X-Admin-Key	全局统计、用户概览、最近会话（limit clamp 到 1–100）；重置用户昵称/密码、删除用户及数据；清全库（confirm='删除'）；改数据目录（环境变量锁定时 409 env_override）

端点计数口径
52 = 路由装饰器中注册到 /api 前缀的 51 条 + main.py 中定义的 GET /api/health。页面入口 /、/admin、/docs 不进 OpenAPI 路径表。路由变动后请以运行期 GET /openapi.json 为准，勿依赖本文档的手抄表格。

5. 诊断评分体系与模型-规则融合算法

5.1 动态评价维度与按模式加权（evaluation/bands.py）

系统依据用户在会话中的实际输入方式（turns.input_mode）动态裁剪评价维度并切换综合分权重，杜绝「打字练习却给发音打分」的逻辑漏洞。模型多给的维度会被后端主动丢弃：打字轮不进 pronunciation / fluency，录音轮不进 written_expression。缺失维度按剩余权重重新归一，不当 0 分；认不出模式才退回等权平均。

作答模式（answer_mode）	pronunciation	fluency	written_expression	grammar_vocab	task_completion	维度数
voice（全部轮次均为录音）	20	20	—	30	30	4 维
typed（全部轮次均为打字）	—	—	35	35	30	3 维
mixed（录音轮与打字轮并存）	15	15	20	25	25	5 维
comparable（跨模式可比子分）	—	—	—	0.50	0.50	2 维

权重按「证据强度」分配而非平均主义：发音在本项目没有声学证据（由模型依转写推断），纯录音中降到 20；纯打字没有发音与流利度证据，原本属于这两维的 40 分转给文字表达（35）与语言复杂度（35）；混合模式下语音证据只覆盖录音轮、文字证据只覆盖打字轮，因此各降一档。**comparable_band** 仅取两种作答都会评的 grammar_vocab 与 task_completion 等权平均，供历史成长曲线与「比上次进步」做跨模式比较——同一场混合会话的 band 与 comparable_band 相差 0.5 属正常现象，报告页应标明是本模式口径。

5.2 客观规则子分计算（backend/app/services/rules.py）

后端基于语音包络元信息与转写文本提取客观特征，按分段线性映射并 clamp 到 [0,1] 后加权合成三个维度的规则子分。所有分段常量均为项目自定，待真人标注数据校准。

规则维度	子项与分段映射（clamp 到 0–1）	合成公式
流利度 rule_fluency	s_wpm：≤70 WPM 记 0，70→130 线性上升，130–200 记满分，>200 按 (w−200)/60 衰减 s_pause：停顿占比 ≤0.15 记 1.0，≥0.45 记 0 s_filler：填充词率 ≤0.03 记 1.0，≥0.15 记 0	S = round(45 + 45 × (0.40·s_wpm + 0.35·s_pause + 0.25·s_filler))；区间 45–90 缺 speech_rate_wpm 或 pause_ratio 时规则分为 None（无语音证据不拿填充词硬凑）
语言范围 rule_complexity（grammar_vocab）	s_mtld：MTLD 30→90 线性映射 s_msl：平均句长 6→16 词/句 s_cx：从句标记密度 = 标记数 / 句数（整词匹配 14 类连接词）	S = round(45 + 45 × (0.45·s_mtld + 0.35·s_msl + 0.20·s_cx))；区间 45–90 无可用句长时把 0.35 权重让给 s_cx；文本过短返回 None
任务完成 rule_task	按场景交际功能清单 TASK_CHECKS（每场景 4–5 项必达交际动作）统计关键词命中率 hit_rate	S = round(40 + 60 × hit_rate)；区间 40–100 清单只测「有没有做」，得体性交由模型判断，故规则权重取 0.6

句数 sentence_count 的三种来源：标点切分 ≥2 句时直接用；否则若有停顿且词数 ≥8，按 min(1+pause_count, 词数//4) 估算；都没有则记为 None。之所以不能退化成「整段词数」，是因为 Chrome 转写通常不带标点，此时 sentence_count 恒为 1，mean_sentence_len 方向是错的。

5.3 「只压不抬」融合策略与单一换算锚

大模型容易给出「好人分（虚高）」，纯规则又无法识别语法硬伤或答非所问。rules.fuse() 因此实现**加权融合 + 单向截断（Clamp）**：final = (1 − w_rule) × model_score + w_rule × rule_score，随后若 model_score − rule_score > 20，强制 final = rule_score + 10 并标记 clamped=true 与压分原因；反之若模型分低于规则分超过 20 分，**绝不用规则分把低分往上抬**，只在报告中标注「请人工复核」。

维度	规则分权重 w_rule	模型分权重	说明
pronunciation	0.00	1.00	无声学证据，发音由模型依转写推断（报告显式注明）
fluency	0.50	0.50	规则分来自语速 / 停顿 / 填充词，模型补韵律与连贯性
grammar_vocab	0.35	0.65	规则分只测语言范围，准确度只能由模型给出，故模型权重大
task_completion	0.60	0.40	清单命中是硬证据，得体性交给模型
written_expression	0.00	1.00	仅打字轮出现，模型依文本判断书面组织与用词

单一换算锚：全项目只在 evaluation/bands.py 定义一次 **S = 10 × B + 10**（反向 B = (S − 10) / 10），向最近 0.5 档取整（floor(B×2+0.5)/2），区间 3.0–9.0；S < 40 分不给 band（显示低于 A2）。CEFR 映射：≥8.5 → C2，≥7.0 → C1，≥5.5 → B2，≥4.0 → B1，≥3.0 → A2。综合分与 band 由代码按维度加权算出并落库，**不是模型给一个 total 就存。**

多量表展示：报告在雅思之外追加各考试的展示值（evaluation/scales.py，量表版本 2026-11，展示顺序 雅思 → CEFR → 托福 → 多邻国 → 四六级）：托福 / 多邻国按 CEFR 档给官方区间（如 B2 → 托福 72–94、多邻国 90–115），四六级无官方 CEFR 换算、只做水平段参考（tier=reference）；高考英语不给分数，只标内容难度「难度 ≈ A2–B1」。**逐维度只映射雅思 + CEFR**——其余考试只有整卷总分或不同构念的子分，硬映射不成立。换算是确定性的、不落库，旧报告读时自动补齐；band 为空（< 40 分）时不给量表值，降级报告标「本次不计分」。

5.4 降级策略与防伪校验

模型不可用（超时、不可达、解析失败、中途丢 Key）时生成降级报告：source=mock，total_score / band / cefr 全部为 null，mock_reason 取 unavailable 或 not_configured，报告标注「示例报告（模型不可用）· 本次不计分」，历史页显示「—」。**降级报告不允许借规则分凑出成绩**——apply_to_report() 遇到 source≠llm 直接原样返回。此外，模型给出的纠错原句 original 必须能在该用户真实转写中匹配到（忽略大小写与标点），找不到直接丢弃，杜绝模型编句子。

6. 前端工程设计与 SM-2 学习闭环

6.1 视图架构与关键交互链路

路由路径	视图组件	核心状态与业务职责
/login	Login.vue	登录/注册双模式；依据 URL 查询参数 reason（expired / password_changed / user_gone）展示精准提示，成功后优先回跳 next
/	Home.vue	6 大场景卡片、句型脚手架预览与 AI 难度建议；顶部集成 LLM 密钥门禁（llmGate.js），未配 Key 时引导至设置页
/practice **/practice/:id**	Practice.vue	多轮语音/打字对话主界面；Web Speech 实时转写、Web Audio 停顿包络采集、SSE 流式气泡渲染、句型提示抽屉、本地录音回放
/report/:id	Report.vue	诊断报告页：总分 / Band / CEFR、维度进度条、可展开的「评分依据（可复现）」验算表、逐句纠错对比、错句原声回放与 85% 阈值跟读重说
/study	Study.vue	四合一学习中心（?tab=review|new|grammar|spoken）：今日到期卡片复习（拼写/选句/造句客观判分）、高考/四六级选词、语法错句辨析、地道口语卡
/history	History.vue	顶部挂载 StudyDashboard.vue（Streak 连续天数、12 周热力图、维度均分、近 7 天变化）；中部 comparable_band 成长曲线；底部多维筛选历史会话
/notes	Notes.vue	随堂笔记工作台：新建、搜索、编辑、删除，可回溯关联的练习会话
/pronunciation	Pronunciation.vue	最小对立对发音辨析训练：针对 /iː/ vs /ɪ/、/θ/ vs /s/ 等中国学习者高频易混音素提供示范与即时比对
/settings	Settings.vue	五大配置分区：模型 Key 配置与连通性测试、可选 TTS、难度与词库偏好、密码修改、清数据与注销账号

路由守卫只判断「有没有 token」，不校验是否过期；过期 token 会让首屏请求失败，由 Axios 响应拦截器统一踢回登录页并附原因码。session store 为纯内存，练习页刷新即丢失进度（有意的简化，避免客户端状态与后端会话不同步）。

6.2 语音采集、包络分析与零上传录音回放

- **双通道并行采集**：按下麦克风时并行启动 SpeechRecognition（en-US）与 getUserMedia 音频流。audio.js 每 50ms 读取时域波形计算 RMS，RMS > 0.02 判为有声帧，累计 speech_time；由有声转无声记为静音起点，再次转有声时若静音 ≥0.15s 则记入 pauses。麦克风被拒时捕获异常并置 capturer=null，对话仍可继续（只是没有音频特征）。
- **零上传隐私回放**：recordings.js 用 MediaRecorder 录制用户原声并写入浏览器本地 IndexedDB（按 sessionId + turnIndex 索引）。在练习页气泡与报告页纠错卡片上可随时「听原句」回放自己的发音并与标准朗读对比，音频数据全程不离开本地浏览器。
- **朗读链路**：默认走浏览器 speechSynthesis（无需 Key，语速档位 0.85 / 1.0 / 1.15）。若配置了兼容 OpenAI /audio/speech 的 TTS，前端先试 POST /api/tts，**任何失败都回落 speechSynthesis**——TTS 挂掉不能连朗读一起没有。

6.3 SM-2 调度与 720 条离线教研题库

卡片来源分两类：① **报告自动建卡**——会话结束生成报告时，后端按 sentence_fixes 的 error_type 自动创建 word / phrase / spelling / grammar 学习卡；② **内置题库主动加卡**——backend/app/data/ 下内置 600 条核心词汇（gaokao / cet4 / cet6 各 200 词，含词性、释义、例句与同反义/形近词）、60 条高频语法卡（tenses / articles / prepositions / clauses 四组各 15 条）与 60 条地道口语卡（spoken.json），合计 720 条，由 tools/check_content.py 一键质检。

反馈档位（result）	客观题判分依据（POST /api/study/items/{id}/review）	SM-2 状态转移（ease E / interval I / reps R / lapses L）
again（忘了 / 答错）	拼写不匹配 term / 语法选错错句 / 口语相似度 < 0.50	E' = clamp(E − 0.2, 1.3, 2.8)；I' = 1 天，但 due_at = now + 10 分钟（当天内还会再出现）；R' = R + 1；L' = L + 1
hard（模糊 / 勉强）	语法题未点选但手动输入含目标改写词 / 口语相似度 ∈ [0.50, 0.70)	E' = clamp(E − 0.15, 1.3, 2.8)；I' = 1（原间隔 ≤0）否则 max(1, round(I × 1.2))；R' = R + 1；L 不变
good（记得 / 答对）	拼写完全匹配 / 语法选对 right 句 / 口语相似度 ≥ 0.70	E' = clamp(E + 0.1, 1.3, 2.8)；I' = 1（原间隔 ≤0）否则 max(1, round(I × 2.5))；R' = R + 1；L 不变

间隔上限 60 天（INTERVAL_CAP_DAYS），初始 ease = 2.5。调度器仅接受 again / hard / good 三档——**没有 easy 档，且 again 时 reps 不归零**，这是口语短周期复习场景下的简化取舍，与经典 SM-2 的四档实现不同。

7. 离线统计验证子系统（evaluation/）与内容质检

为支撑「可验证的 AI 英语口语诊断陪练」这一核心命题，evaluation/ 完全使用 Python 标准库实现心理测量学与医学统计中常用的一致性检验指标，用于量化「多位教师盲评之间的内部信度」与「系统自动评分与人类专家之间的效度」。刻意不依赖 numpy / scipy，代价是 ICC 需手写双向随机效应方差分析，收益是在任何 Python 3 环境下都能一键复现。

统计指标	实现函数（agreement.py）	数学定义与检验目标	参考判读标准
ICC(2,1) / ICC(2,k)	icc_2_1() / icc_2_k()（共用 _icc(matrix, average)）	双向随机效应 ANOVA 绝对一致性：分解 MS_R / MS_C / MS_E；ICC(2,1) 分母 MS_R+(k−1)MS_E+k(MS_C−MS_E)/n，ICC(2,k) 分母 MS_R+(MS_C−MS_E)/n	Koo & Li (2016)：<0.50 差，0.50–0.75 中等，0.75–0.90 良好，>0.90 优秀
Cohen / Fleiss Kappa	cohens_kappa() / fleiss_kappa()	校正随机一致期望 P_e 后的类别型一致性系数（对齐 CEFR 档位）；Fleiss 支持 2 人以上，行=样本、列=评分者	Landis & Koch (1977)：0.41–0.60 中等，0.61–0.80 较强，>0.80 几乎完全一致
Pearson r / Spearman ρ	pearson() / spearman()	系统连续分与教师均分的线性相关与秩相关；_ranks() 对并列取平均秩	r、ρ ≥ 0.75 表征系统分与人评排序高度吻合
MAE / RMSE	mae() / rmse()	平均绝对误差与均方根误差（0–100 分制量纲），直观反映系统分偏离人评均值的幅度	越小越好
Bland-Altman 分析	bland_altman()	计算系统分减人评均分的均值偏差 bias、标准差 sd 及 95% 一致性界限 [bias ± 1.96·sd]，并统计落在界限内的样本比例	bias 接近 0 说明无系统性高估/低估；≥95% 样本应落在 LoA 内
系统档位一致性	validate.py _system_band_block()	系统 CEFR 档 vs 人评多数票（_majority_cefr）：完全一致率 exact_rate、相邻率 adjacent_rate（相差 ≤1 档）、平均档差 mean_abs_cefr_distance、Cohen kappa（含逐人 kappa_per_human）	合成样本参考值：exact 0.70、adjacent 1.00、平均档差 0.30、kappa 0.49（中等）

边界行为与样本量陷阱
① 有效样本 n < 3 时只返回 {n, raters, warning}，不计算任何指标；② 系统分比较要求 n ≥ 3 才输出 system_vs_human_mean；③ 档位 Kappa 要求至少 2 条完整档位样本；④ ICC 与相关性使用「人评分齐全」的过滤后样本，而 Kappa 用的是原始行中档位齐全的子集——两类缺失模式不同时，两部分报告的 n 可能不一致，需各自注明样本数。

离线验证与内容质检 CLI（仓库根目录，PowerShell 7）：

```
# 1) 生成 20 条固定随机种子（seed=42）合成盲评样本 evaluation/demo_data.csv
python -m evaluation.make_demo

# 2) 计算人评内部信度、系统 vs 人评连续分与 CEFR 档位一致性，输出终端报告与 JSON
python -X utf8 -m evaluation.validate --csv evaluation/demo_data.csv \
 --raters human1,human2 --system system \
 --bands human1_band,human2_band --system-band system_band \
 --out evaluation/demo_report.json

# 3) 静态校验 600 条词库（含不规则动词屈折形态匹配）、60 语法卡、60 口语卡
python tools/check_content.py # 返回码 0 表示 720 条教研数据全部通过
```

数据采集规范（真人数据尚未采集）：2–3 名英语教师独立打分且互不可见；对系统分盲评；共用同一份对齐 CEFR / IELTS 描述语的 rubric；每样本至少两人评，建议 ≥20 条；保留原始录音与转写以保证可复现。答辩若被追问「这个 ICC 是真的吗」，正确答案是：**脚本可信、数值是合成的，真实数据正在采集。**

8. 安全加固、部署运行与工程边界

8.1 安全与鲁棒性加固

安全 / 可靠性维度	工程实现机制与代码落点
自带密钥零残留（BYOK）	服务端不保存 LLM_API_KEY（.env 里写了也不读取）；用户密钥仅经 X-LLM-Key 请求头在内存中转发至上游模型，不写库、不回显、不进错误日志。
SSRF 内网探测防护	services/outbound.py 解析用户传入 Base URL 的 DNS 并校验 IP，默认拒绝 loopback / private / link-local 等内网地址；仅当 ALLOW_PRIVATE_LLM_HOSTS=1 时放行本地 Ollama。
会话代次与改密踢人	users.token_version 随 JWT 载荷下发；改密或管理员重置密码时自增 1，旧 Token 访问任何接口立即 401，响应头附 X-Auth-Reason: password_changed。
登录防暴力破解	routers/auth.py 维护滑动窗口失败计数器，连续输错达阈值后临时锁定并返回 429，登录成功立即清零；账号不存在与密码错误返回同一文案，避免用户枚举。
流式原子性与幂等报告	SSE 流式对话仅在完整接收 AI 回复后写入 turns，杜绝半截脏数据；POST /finish 对已生成报告的会话幂等返回已有报告，不重复消耗 Token。
弱密钥自动轮换	config.py 启动时检测 JWT_SECRET / ADMIN_KEY 是否为空或公开默认值，自动生成 token_urlsafe 随机值写回 .env；真实环境变量提供的值只告警不改写。

8.2 安装、启动与生产部署

- **开发环境一键启动**：首次执行 **.\setup.ps1** 自动创建 backend\.venv 并安装前后端依赖（Node 目录按 tools\node → ..\.tools\node-* → 系统 PATH 顺序探测）；日常演示双击 **start-all.bat**，脚本自动清理被占用的 8000 端口，拉起后端（127.0.0.1:8000）与前端（127.0.0.1:5173）两个窗口并打开浏览器。
- **生产部署建议**：cd frontend && npm run build 生成静态产物后，用 Nginx 托管 frontend/dist（配置 try_files $uri $uri/ /index.html 支持 History 路由回退），并将 location /api 反代至 Uvicorn / Gunicorn 进程；同时在真实进程环境变量中注入强随机 JWT_SECRET、ADMIN_KEY 与 DATABASE_URL。当前后端不托管 dist 产物，演示形态等同于「在演示机上跑两个 dev 进程」，两服务均只监听回环地址。

8.3 关键参数默认值速查

参数项	默认值	定义位置	参数项	默认值	定义位置
后端监听地址	127.0.0.1:8000	start-backend.bat	前端监听地址	127.0.0.1:5173	frontend/vite.config.js
JWT 有效期	10080 分钟（7 天）	app/config.py	默认大模型	deepseek-chat	app/config.py
对话保留上下文	最近 8 条消息（约 4 轮）	app/services/llm.py	建议结束条件	3 目标达成或 6 轮上限	app/services/agent.py
对话 / 评分温度	0.7 / 0.2	llm.py / scoring.py	压分触发 / 回落	高 20 分压回规则分 +10	app/services/rules.py
有声判定 RMS	0.02（50ms 采样）	src/utils/audio.js	跟读通关相似度	≥ 0.85	app/routers/exercises.py
停顿计入阈值	≥ 0.15 s	src/utils/audio.js	SM-2 间隔上限 / ease 域	60 天 / [1.3, 2.8]	app/services/srs.py
默认难度 / 词库	medium / cet4	app/models.py	建议评估样本量	≥ 20 条	docs/validation.md

8.4 已知限制与技术债

编号	问题	影响	建议
TD-A	finish 无「最少轮次」校验	—	已修复：无 user turn 时返回 400（sessions.py:321-324）
TD-B	role / status 仍无枚举约束（difficulty 已白名单校验）	脏数据仍可绕过前端写入这两列	给 status / role 加 CheckConstraint 或 Enum
TD-C	无 CI 配置与 lint 配置	backend/tests 已有 168 条 unittest 全绿（2026-11-14）	接 CI 跑 unittest；agreement.py 已知值测试仍缺
TD-D	音频阈值硬编码（RMS 0.02、停顿 0.15s）	不同麦克风 / 噪声环境下语速与停顿失真	暴露为配置项，或做环境噪声自校准
TD-E	历史列表无分页；管理台 N+1 查询	—	已修复：sessions.py:470-484 支持 limit/offset；admin.py:84-94 已改 GROUP BY
TD-F	语音识别依赖 Chrome 且走云端	网络受限时转写失败，Firefox / Safari 不可用	已有「手动输入」兜底；如需更稳可接后端 ASR
TD-G	规则权重未在真人标注数据上校准	规则分的绝对水平缺外部效度支撑	采集 20–30 条真人评分后用 evaluation/ 反推校准权重
TD-H	发音维度仅由转写推断	方法论上最大短板	接入音素级 ASR 置信度或强制对齐（如 wav2vec2）替代「从转写猜发音」

演进优先级建议
P0：真实 LLM Key 下的完整回归（报告 source 标记已完成）；P1：采集 20–30 条真人评分产出真实 agreement 报告（把「可验证」从工程自测升级为真实结论，是本题核心加分点）；P2：补 agreement.py 已知值测试、发音维度接入声学证据；P3：场景配置化（存库 / JSON，支持教师自定义场景与 rubric）、部署方案落地（Nginx + Docker Compose）。